

Предсказание мощности газотурбинной электростанции.

на основе датасета `Folds5x2_pp_TP.csv`



Введение.

По мере приближения к новой эре в энергетической отрасли, мы понимаем что энергетические системы должны быть более экологичными и в то же время эффективными.

На сегодняшний день машинное обучение может прекрасно себя проявлять в подобных сценариях и помочь в решении данного вопроса.

И как мы понимаем в такой важной сфере, как производство электроэнергии, любое повышение эффективности является значительным достижением как для отрасли, так и для всего человечества.

Использование инструментов машинного обучения позволяет нам отслеживать показатели и прогнозировать в реальном времени, что более точно отражает картину, в отличии от общих термодинамических расчетов.

Таким образом успешное внедрение машинного обучения может стать большим преимуществом в энергетической отрасли.

Содержание.

- 1 — О датасете.
- 2 — Цели проекта.
- 3 — Первичный анализ. Глубокий анализ. EDA.
- 4 — Важность признаков.
- 5 — Инженерия переменных.
- 6 — Построение модели.
- 7 — Итоги.



0 датасете.

Датасет создан на основе **Combined Cycle Power Plant (CCPP)**.

Это **электростанция комбинированного цикла**, представляющая собой совокупность тепловых двигателей, которые работают в тандеме от одного и того же источника тепла. Использует **газовые турбины** и **паровые турбины**, объединённые в один цикл. Тепло от выхлопных газов первой турбины используется для нагрева воды и создания пара, который вращает вторую — это повышает эффективность по сравнению с обычными одиночными установками.

Содержит данные о работе электростанции и используется для **регрессии** — предсказания электрической мощности по параметрам окружающей среды.

Источник: UCI Machine Learning Repository

Период сбора: 2006–2011

Folds5x2: намёк на кросс-валидацию 5×2 (5 повторов по 2 фолда).



Цели проекта.

Провести комплексный анализ данных о процессе работы газотурбинной установки.

Выявить ключевые факторы, влияющие на выходную мощность.

Построить модель, способную прогнозировать значение мощности в зависимости от параметров окружающей среды.





Первичный анализ.

Структура данных.

Количество записей: 9568 наблюдений.

Целевая переменная: PE - выходная электрическая мощность.

Переменн ая	Описание	Ед. изм.
AT	Температура окружающей среды	(°C)
V	Вакуум в выхлопной системе	(cm Hg)
AP	Атмосферное давление	(mbar)
RH	Относительная влажность	(%)

Разведочный анализ данных (EDA)

	AT	V	AP	RH	PE
count	9525.000000	9533.000000	9503.000000	9510.000000	9568.000000
mean	19.641594	54.311154	1013.250053	73.291181	454.365009
std	7.454601	12.705674	5.934166	14.593837	17.066995
min	1.810000	25.360000	992.890000	25.560000	420.260000
25%	13.510000	41.740000	1009.090000	63.320000	439.750000
50%	20.320000	52.080000	1012.930000	74.955000	451.550000
75%	25.720000	66.540000	1017.250000	84.810000	468.430000
max	37.110000	81.560000	1033.300000	100.160000	495.760000


Имеются небольшие пропуски в признаках (показатели **count**)

Мощность станции (PE): 420–496 МВт, среднее ≈ 454 МВт. колеблется в пределах ~75 МВт. Рабочая зона близка к полной нагрузке.

Ключевые факторы: температура (AT) снижает мощность, вакуум (V) повышает.

Второстепенные факторы: давление (AP) и влажность (RH) оказывают слабое влияние.

Тепловая карта корреляций.



Показатели корреляции **Пирсона** и **Спирмена** почти совпадают, это говорит о том, что:

Связь между переменными близка к линейной

- Пирсон оценивает именно линейную зависимость.
- Спирмен оценивает монотонную (по рангам).
- Оба коэффициента почти одинаковы, значит зависимость не только монотонная, но и хорошо аппроксимируется прямой линией.

Нет сильных выбросов или нелинейных искажений

- Спирмен более устойчив к выбросам.
- Если бы в данных были выбросы или нелинейные тренды (например, экспоненциальные или логарифмические), то значения могли бы заметно различаться.

Ранги и сами значения переменных упорядочены схожим образом


- То есть порядок наблюдений по величине переменной почти совпадает с их линейной зависимостью.

Можно уверенно использовать **линейные методы анализа** (например, линейную регрессию).


Пара переменных	Коэффициент	
AT & PE	-0.95	Сильная отрицательная связь. Повышение температуры резко снижает эффективность. Может быть связано с перегревом оборудования
V & PE	-0.87	Сильная отрицательная связь. Большой расход воздуха снижает КПД.
AP & PE	0.52	Умеренная положительная связь. Давление способствует эффективности.
RH & PE	0.39	Слабая положительная связь. Влажность может улучшать теплообмен.
AT & V	0.84	Сильная положительная связь. При росте температуры увеличивается расход воздуха.
AT & AP	-0.51	Умеренная отрицательная связь. Повышение температуры связано с понижением давления.
AT & RH	-0.54	Умеренная отрицательная связь. Теплый воздух менее влажный.

Regplot


Зависимость целевой переменной.



Зависимости признаков.



Пропущенные значения




	target_with_missing	tested_against	p_value
13	RH	V	0.002315
15	RH	PE	0.002599
12	RH	AT	0.013429
14	RH	AP	0.013436
0	AT	V	0.018164
3	AT	PE	0.047517
7	V	PE	0.051403
5	V	AP	0.060226
2	AT	RH	0.073809
4	V	AT	0.093321
6	V	RH	0.219823
9	AP	V	0.265131
1	AT	AP	0.367500
8	AP	AT	0.554489
11	AP	PE	0.610037
10	AP	RH	0.760231

Доля пропусков не превышает 1%, что является очень низким показателем.

Возможные причины появления: сбой сенсора, потеря данных при передаче по сети, тех. обслуживание.


Нет признаков систематической зависимости.



Для **MAR (AT, RH, частично V)**: лучше использовать более «умные» методы восстановления, например:

KNNImputer (учитывает соседние наблюдения)


IterativeImputer (моделирует пропуски через регрессию на основе других признаков).



Для **MCAR (AP)**: можно спокойно удалять строки или использовать простые методы, заполнять медианой/средним, случайным.

Признак	Тип пропусков	Обоснование
RH	MAR	Пропуски зависят от AT, V, AP, PE
AT	MAR	Пропуски зависят от V и PE
V	Смешанный (ближе к MAR)	Слабая зависимость от PE и AP
AP	MCAR	Нет зависимости от других переменных

Выбросы.



AT (температура): распределение компактное, выбросов почти нет.

V (объёмный расход): распределение чистое, выбросов не видно.

AP (давление): выбросы

- низ (< 997)
- верх (> 1029)




RH (влажность):

- - ниже значения 39.

Учитывая низкий процент можно исключить из модели наблюдения имеющие выбросы.

Анализ важности признаков.





Feature Importance	Быстрый, встроенный	Смещён при мультиколлиарности
Permutation Importance	Устойчивый, модель-агностичный	Медленный, зависит от метрики
SHAP	Точный, локальный и глобальный вклад	Ресурсоёмкий, сложнее интерпретировать



Вне зависимости от подхода получен схожий результат. Это подтверждает, что модель почти полностью «держится» на температуре и частично на расходе воздуха.


Инженерия признаков.

Пропущенные значения.



Признак	Оригина льная дисперси я	Mean	Δ Mean	Median	Δ Median	Random	Δ Random	KNN	Δ KNN	Iterative	Δ Iterative	✓ Лучший метод
AT	55.5711	55.3213	0.2498	55.3234	0.2477	55.5443	0.0268	55.5459	0.0252	55.5464	0.0247	Iterative
V	161.4342	160.8436	0.5906	160.8617	0.5724	161.4021	0.0321	161.4455	0.0114	161.3398	0.0944	KNN
AP	35.2143	34.9751	0.2393	34.9758	0.2386	35.1859	0.0284	35.1510	0.0633	35.0515	0.1628	Random
RH	212.9801	211.6889	1.2912	211.7056	1.2745	213.2277	0.2477	212.5545	0.4256	212.2231	0.7569	Random

Трансформация и масштабирование



Трансформация переменных

Несмотря на то, что распределение исходных переменных близко к нормальному, **трансформация не улучшила** метрики модели. Было решено отказаться от неё, чтобы избежать излишнего усложнения.

Масштабирование переменных

Стандартизация и масштабирование переменных являются важными шагами для большинства алгоритмов машинного обучения.

В качестве метода был выбран

RobustScaler

- Центрирует по медиане и масштабирует по межквартильному размаху (IQR).

Устойчив к выбросам, как видно на графике — боксы компактнее.

- Отличный выбор, если в данных есть шум или экстремальные значения.

Построение модели.

Для решения задачи регрессии будут рассмотрены следующие популярные и эффективные алгоритмы машинного обучения:



Linear Regression (Линейная регрессия)

- Базовый статистический метод.
- Быстрая интерпретация коэффициентов.
- Чувствителен к мультиколлинеарности и выбросам.



Random Forest Regressor (Случайный лес)

- Ансамбль решающих деревьев.
- Устойчив к переобучению.
- Хорошо работает с нелинейными зависимостями.



Gradient Boosting Regressor (Градиентный бустинг)

- Последовательное улучшение слабых моделей.
- Высокая точность на табличных данных.
- Требует настройки гиперпараметров.



SVR (Метод опорных векторов)

- Основан на максимизации границы.
- Эффективен при небольшом объеме данных.
- Чувствителен к выбору ядра и параметров.



KNN Regression (Метод ближайших соседей)

- Прогноз на основе ближайших точек.
- Простая и интуитивная реализация.
- Чувствителен к масштабу признаков и шуму.



XGBoost Regression (Экстремальный градиентный бустинг)

- Оптимизированная реализация градиентного бустинга.
- Высокая производительность и точность.
- Поддержка регуляризации и ранней остановки.

Оценка моделей будет проводиться по метрикам: R^2 , MAE, MSE, RMSE — для объективного сравнения качества предсказаний.

Baseline model (Linear Regression)

Оригинальный датасет. Удалены наблюдения с пропусками.

Train R^2 : 0.9271

MAE: 3.63

MSE: 21.08


RMSE: 4.59

Test R^2 : 0.9325

MAE: 3.60


MSE: 19.95

RMSE: 4.47







Производительность модели.

Pipeline



Сравнение метрик.

Metrics to compare





Train R^2 : 0.9951

MAE: 0.86

MSE: 1.39

RMSE: 1.18


Test R^2 : 0.9673

MAE: 2.22

MSE: 9.77

RMSE: 3.13

Final Model (GradientBoostingRegressor)





Ключевые выводы

Все модели отлично отрабатывают и имеют хорошие показатели , отсутствие переобучения и быструю предиктивную скорость. Лучшей моделью и более сбалансированной является **GradienBoostingRegressor**.

Две значимые переменные: AT, V являются основными предикторами мощности.

Регрессия: задача прогнозирования выходной мощности.

Отсутствие категориальных переменных: упрощает предварительную обработку данных.

Качество и кол-во наблюдений: позволяет добиться высоких результатов в прогнозировании.

Итоги.

Построена и обучена система прогнозирования выходной мощности энергетической установки на основе регрессионных моделей.

- **Проведён комплексный анализ данных:**

- Выявлены ключевые факторы, влияющие на показатели мощности.
- Реализованы методы замены пропущенных значений с оценкой сохранения дисперсии по ключевым признакам. Выбран оптимальный метод для каждого признака.
- Реализован модуль масштабирования признаков и автоматизированный pipeline, обеспечивающий воспроизводимость и гибкость при обучении моделей.

Реализована система оценки риска: по метрикам качества (R^2 , MSE, MAE, RMSE). Выявлены лидеры по точности и стабильности предсказаний.

Визуализированы результаты: предсказаний и фактических значений, регрессионные линии, диагонали идеала, расчёт переобучения и сортировка моделей по качеству.

- **Получен инструмент для технического применения:**

- Надёжное прогнозирование выходной мощности по входным параметрам установки.
- Возможность интеграции в производственные системы мониторинга и оптимизации.

Достигнуты целевые показатели по точности, устойчивости и прозрачности модели.

Работа готова к масштабированию и внедрению в реальные процессы.

